

Laborator 3 - Simularea variabilelor aleatoare. (Ilustrații ale LNM și TLC. Metodele Monte Carlo.)

I. Distribuții continue remarcabile

RStudio. Nu uitați să alegeți directorul de lucru: **Session** → **Set Working Directory** → **Choose Directory**.

Exercițiu rezolvat. Reprezentați grafic funcția de densitate a distribuției exponențiale, $Exp(\lambda)$ ($\lambda > 0$).

Această distribuție se anulează pe toată semiaxa negativă, deci este suficient să o reprezentăm pe semiaxa pozitivă (vom folosi, de fapt, un interval de forma $[0, a]$).

```
density_exponential = function(lambda, n, a) {  
  x = seq(0, a, n);  
  y = dexp(x, lambda);  
  plot(x, y, type = 'l');  
}
```

Exercițiu propus.

I.1. Scrieți o funcție care să reprezinte grafic densitățile următoarelor distribuții:

- (a) $N(\mu, \sigma^2)$.
- (b) $Student(r)$.
- (c) $Gamma(\alpha, \lambda)$.

II. Legea numerelor mari (LNM).

Fie X_i , $1 \leq i \leq n$, un șir de variabile aleatoare independente și identic distribuite, media lor aritmetică este

$$\bar{x}_n = \frac{X_1 + X_2 + \dots + X_n}{n},$$

Atunci, conform LNM, $\bar{x}_n \rightarrow \mu$, unde $\mu = E[X_i]$, $\forall 1 \leq i \leq n$.

Exercițiu rezolvat. Verificați LNM utilizând șirul de variabile $X_i : Poisson(\lambda)$, $1 \leq i \leq n$. (Se știe că $E[X_i] = \lambda$.)

```
LLN_Poisson = function(lambda, n) {  
  sum = 0;  
  for(i in 1:n) {  
    u = rpois(1, lambda);  
    sum = sum + u;  
  }  
  return(sum/n);  
}
```

O variantă mai simplă și mai rapidă:

```
LLN_Poisson = function(lambda, n) {  
  return(mean(rpois(n, lambda)));  
}
```

Exercițiu rezolvat. Verificați LNM utilizând șirul de variabile $X_i : \text{Gamma}(\alpha, \lambda)$, $1 \leq i \leq n$. (Se știe că $\mathbb{E}[X_i] = \alpha/\lambda$.)

Folosim aici doar varianta mai simplă:

```
LLN_Gamma = function(alfa, lambda, n) {
  return(mean(rgamma(n, alfa, lambda)));
}
```

Exerciții propuse.

II.1. Scrieți câte o funcție care să verifice LNM pentru următoarele șiruri de variabile aleatoare

(a) $X_i : \text{Exponential}(\lambda)$, $1 \leq i \leq n$. (Știm că $\mathbb{E}[X_i] = 1/\lambda$.)

(b) $X_i : B(m, p)$, $1 \leq i \leq n$. (Știm că $\mathbb{E}[X_i] = mp$.)

II.2 Rezolvați același exercițiu pentru șirul de variabile aleatoare $X_i : \text{Student}(r)$, $1 \leq i \leq n$, pentru care se știe că $\mathbb{E}[X_i] = 0$. Comparați rezultatele cu valorile exacte pentru următorii parametri: $n \in \{1000, 10000, 100000, 1000000\}$ and $r \in \{2, 3, 4, 5\}$.

III. Teorema Limită Centrală (TLC).

Fie X_i , $1 \leq i \leq n$, un șir de variabile aleatoare independente și identic distribuite și fie

$$\bar{x}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

media lor aritmetică, atunci, conform TLC, \bar{x}_n (pentru valori foarte mari ale lui n) urmează o distribuție $N(\mu, \sigma^2)$.

După standardizarea mediei de selecție obținem că $\frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} : N(0, 1)$.

Exercițiu rezolvat. Verificați TLC folosind șirul de variabile aleatoare $X_i : \text{Poisson}(\lambda)$, $1 \leq i \leq n$. (Se știe că $\mathbb{E}[X_i] = \lambda$ și $\text{Var}[X_i] = \lambda$.)

TLC spune că

$$P\left(\frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} \leq z\right) \cong P(Z \leq z),$$

Unde $z \in \mathbb{R}$ și $Z : N(0, 1)$ - legea normală standard. Probabilitatea din dreapta este $pnorm(z)$, în timp ce probabilitatea din stânga poate fi aproximată prin astfel: fie N (un număr foarte mare) de eșantioane aleatoare simple, fiecare de dimensiune n , $(X_i^k)_{i=1, n}^{k=1, N}$, apoi calculăm

$$P^N(z) = \frac{|\{k : \bar{x}_n^k \leq z\sigma/\sqrt{n} + \mu\}|}{N}.$$

(X_i^k sunt valori simulate conform distribuției date - Poisson în cazul exercițiului de față). Se compară apoi această probabilitate cu $pnorm(z)$.

```

CLT_Poisson = function(lambda, n, N, z) {
  expectation = lambda;
  st_dev = sqrt(lambda);
  upper_bound = z * st_dev/sqrt(n) + expectation;
  sum = 0;
  for(i in 1:N) {
    x_n = mean(rpois(n, lambda));
    if(x_n <= upper_bound) {
      sum = sum + 1;
    }
  }
  return(sum/N);
}

```

Remarcă: n ar trebui să fie cel puțin 30; e. g., $n = 30$, $N = 10000$, $z \in \{0, 1, 1.5, 2\}$.

Exerciții propuse.

III.1. Scrieți o funcție care să verifice TLC folosind șirul de variabile aleatoare $X_i : \text{Exponential}(\lambda)$, $1 \leq i \leq n$. (Știm că $\mathbb{E}[X_i] = 1/\lambda$, $\text{Var}[X_i] = 1/\lambda^2$.)

III.2 Rezolvați același exercițiu pentru șirul de variabile aleatoare $X_i : \text{Gamma}(\alpha, \lambda)$, $1 \leq i \leq n$. (We know that $\mathbb{E}[X_i] = \alpha/\lambda$ and $\text{Var}[X_i] = \alpha/\lambda^2$.) Folosiți $n = 50$, $N \in \{5000, 10000, 20000\}$ și $z \in \{0.5, 1, 1.5, 2, 2.5\}$.

IV. Estimarea ariilor și a volumelor

RStudio. Nu uitați să va setați directorul de lucru: **Session** → **Set Working Directory** → **Choose Directory**.

Exercițiu rezolvat. Aria discului unitate este π . Acoperim discul cu un pătrat de dimensiuni 2 pe 2 și estimăm numărul π folosind 10000, 50000 și 100000 valori uniforme aleatoare. Comparăm apoi rezultatele cu valoarea cunoscută a lui $\pi = 3.14159265358\dots$

Discul unitate este inclus în $[-1, 1] \times [-1, 1]$. Următoarea funcție estimează π utilizând N numere aleatoare.

```

disc_area = function(N) {
  N_C = 0;
  for(i in 1:N) {
    x = runif(1, -1, 1);
    y = runif(1, -1, 1);
    if(x*x + y*y <= 1)
      N_C = N_C + 1;
  }
  return(4*N_C/N); }

```

Dacă am estimat o valoare α_{actual} prin metoda Monte Carlo și obținem α_{MC} , putem măsura eroarea făcută (aceea de a folosi α_{MC} în loc de α_{actual}) în cel puțin două moduri:

- **Eroarea absolută:** $\epsilon_{abs} = |\alpha_{MC} - \alpha_{actual}|$.
- **Eroarea relativă:** $\epsilon_{rel} = \frac{|\alpha_{MC} - \alpha_{actual}|}{|\alpha_{actual}|}$. Această valoare poate fi scrisă și procentual, obținând **eroarea procentuală:** $\epsilon_{per} = \epsilon_{rel} \cdot 100\%$.

Exerciții propuse.

- IV.1. Estimați volumul sferei unitate (care este $4\pi/3$) folosind eșantioane de numere aleatoare de dimensiuni diferite și apoi calculați erorile (absolută și relativă) corespunzătoare.
- IV.2. Estimați aria dintre parabola de ecuație $y = y = -2x^2 + 5x - 2$ și axa Ox (abscisă) - folosind 10000 valori uniforme. Determinați aria exactă prin integrare și calculați eroarea relativă.

Indicație: parabola intersectează axa Ox în punctele $(1/2, 0)$ și $(2, 0)$ și are vârful în $(5/4, 9/8)$. Un domeniu rectangular din planul real care acoperă această arie poate fi $[0, 2] \times [0, 2]$.

V. Integrarea Monte Carlo

Exercițiu rezolvat. Estimați valoarea următoarei integrale folosind 20000 și apoi 50000 de valori aleatoare (determinați 30 astfel de aproximări pentru fiecare eșantion și calculați câte o medie și câte o deviație standard).

$$\int_0^{10} e^{-u^2/2} du.$$

Următoarea funcție oferă o estimare pentru un eșantion de dimensiune N

```
MC_integration = function(N) {  
  sum = 0;  
  for(i in 1:N) {  
    u = runif(1, 0, 10);  
    sum = sum + exp(-u*u/2);  
  }  
  return(10*sum/N);  
}
```

Putem calcula o medie pentru $k = 30$ astfel de aproximări și și deviația standard corespunzătoare folosind următoarea funcție.

```
MC_integr_average = function(k, N) {  
  for(i in 1:k)  
    estimates[i] = MC_integration(N);  
  print(mean(estimates));  
  print(sd(estimates));  
}
```

În urma execuției acestei funcții obținem

```
> MC_integr_average(30, 20000  
[1] 1.249768  
[1] 0.02327472  
> MC_integr_average(30, 50000  
[1] 1.253072  
[1] 0.01373724
```

Exercițiu rezolvat. Estimați valoarea următoarei integrale folosind 20000 și apoi 50000 de valori aleatoare (determinați 30 astfel de aproximări pentru fiecare eșantion și calculați câte

o medie și câte o deviație standard), utilizând metoda MC îmbunătățită, anume cu distribuția exponențială ($\lambda = 1$)

$$\int_0^{+\infty} e^{-u^2} du.$$

(Valoarea exactă acestei integrale este $\sqrt{\pi}/2 \approx 0.8862269$.)

Mai întâi, următoarea funcție oferă o estimare pentru un eșantion de dimensiune N

```
MC_improved_integration = function(N) {
  sum = 0;
  for(i in 1:N) {
    u = rexp(1, 1);
    sum = sum + exp(-u*u)/exp(-u);
  }
  return(sum/N);
}
```

Putem calcula o medie pentru $k = 30$ astfel de aproximări și și deviația standard corespunzătoare folosind următoarea funcție.

```
MC_imprvd_integr_average = function(k, N) {
  estimates = 0;
  for(i in 1:k)
    estimates[i] = MC_improved_integration(N);
  print(mean(estimates));
  print(sd(estimates));
}
```

În urma execuției acestei funcții obținem

```
> MC_imprvd_integr_average(30, 20000)
[1] 0.8858024
[1] 0.002743676
> MC_imprvd_integr_average(30, 50000)
[1] 0.8861285
[1] 0.00213069
```

Exerciții propuse.

V.1. ((a) sau (b) și (c) sau (d)) Estimați valorile următoarelor integrale (comparând estimarea cu valoarea exactă) și calculați erorile absolute și relative corespunzătoare:

$$(a) \int_0^{\pi} \sin^2 x \, dx = \frac{\pi}{2}; (b) \int_1^4 e^x \, dx = 51.87987;$$

$$(c) \int_0^1 \frac{dx}{\sqrt{1-x^2}} = \frac{\pi}{2}; (d) \int_1^{+\infty} \frac{dx}{4x^2-1} = \ln 3/4.$$

V.2 Estimați valoarea următoarei integrale utilizând metoda MC îmbunătățită, cu distribuția exponențială ($\lambda = 3$, $N = 50000$)

$$\int_0^{+\infty} e^{-2u^2} du = \sqrt{\pi/8}.$$

Comparați rezultatul cu valoarea exactă, și calculați erorile absolute și relative corespunzătoare. Determinați apoi 30 astfel de aproximări și calculați o medie și o deviație standard. (Vezi exercițiul rezolvat.)

VI. Estimarea mediilor

Exercițiu rezolvat. Modelul stochastic pentru numărul de erori (bug-uri) găsite într-un nou produs software se poate descrie după cum urmează. Zilnic cei care testează produsul determină un număr aleator de erori care sunt apoi corectate. Numărul de erori găsite în ziua i urmează o distribuție Poisson(λ_i) al cărei parametru este cel mai mic număr de erori din cele două zile anterioare:

$$\lambda_i = \min \{X_{i-2}, X_{i-1}\}.$$

Care este numărul mediu de zile în care sunt detectate toate erorile? (Presupunem că în primele două zile sunt găsite 31 și 27 erori, respectiv.) Folosiți $N = 10000$ de simulări ("runs") pentru estimatorul Monte Carlo.

Generăm un număr de erori pentru fiecare zi, până când acest număr este 0. Următoarea funcție oferă numărul de zile până când nu mai apar erori (pentru o singură simulare - "run").

```
Nr_days = function() {  
  nr_days = 1;  
  last_errors = c(27, 31);  
  nr_errors = 27;  
  while(nr_errors > 0) {  
    lambda = min(last_errors);  
    nr_errors = rpois(1, lambda);  
    last_errors = c(nr_errors, last_errors[1]) ;  
    nr_days = nr_days + 1;  
  }  
  return(nr_days);  
}
```

Executăm această funcție de $N = 10000$ de ori și returnăm media obținută

```
MC_nr_days = function(N) {  
  s = 0;  
  for(i in 1:N)  
    s = s + Nr_days();  
  return(s/N);  
}
```

Rezultatul este 28.0686, astfel, în aproximativ 4 săptămâni toate erorile vor fi găsite.

Exerciții propuse.

VI.1 Rezolvați din nou exercițiul anterior considerând că λ_i este media numărului de erori din cele trei zile anterioare (În primele trei zile numărul de erori găsite a fost de 9, 15 și 13, respectiv).